

Claude Mythos 분석 및 국내 금융사 적용 방안

Anthropic의 미공개 프론티어 모델 Mythos의 핵심 기술을 분석하고, 최신 공개 Claude 모델(Opus 4.7)을 활용한 국내 금융기관 사이버보안 강화 방안을 제시합니다.

SECTION 01

Executive Summary

2026년 4월 7일, Anthropic은 자사 프론티어 모델 **Claude Mythos Preview**를 발표하면서 사이버보안 업계에 충격을 안겼습니다. Mythos는 모든 주요 운영체제와 웹 브라우저에서 제로데이 취약점을 자율적으로 발견하고 익스플로잇을 작성할 수 있는 능력을 입증했습니다.

본 보고서는 세 가지 핵심 질문에 답합니다:

- **Mythos에 적용된 기술을 최신 공개 Claude 모델로 구현할 수 있는가?** → 취약점 발견의 80% 이상은 가능, 고급 익스플로잇 개발은 제한적
- **아직 비공개인 Mythos를 실제 유사하게 구현할 수 있는가?** → Mythos Research Edition이 25-50배 저렴한 비용으로 발견 단계 재현 성공
- **국내 금융사에 어떻게 적용할 수 있는가?** → AWS Bedrock + Claude Opus 4.7 기반 4단계 보안 강화 로드맵 제시

27년

OpenBSD 취약점 미발견 기간

181회

Firefox 익스플로잇 성공
vs Opus 4.6의 2회

\$50 이하

취약점 1건 발견 비용

수천 건

발견된 제로데이 취약점

▲ 핵심 경고

Anthropic은 6-12개월 내에 적대세력이 유사 능력을 복제할 수 있다고 경고했습니다. ECB는 이미 은행들을 소집했으며, 국내 금융사도 선제적 대응이 필수적입니다.

SECTION 02

Mythos 핵심 기술 분석

Mythos의 사이버보안 능력은 특별한 보안 훈련의 결과가 아닌, **코드 이해력, 추론 능력, 자율성의 일반적 개선에서 자연스럽게 발현된** 것입니다. Anthropic 레드팀에 따르면 "패치 능력의 향상이 곧 익스플로잇 능력의 향상"으로 이어졌습니다.

핵심 발견 사례

OpenBSD TCP SACK - 27년 된 취약점

TCP 시퀀스 번호의 정수 오버플로우와 NULL 포인터 역참조를 연결하는 논리적 결함. 두 개의 패킷만으로 서버 다운. 캠페인 비용 \$20,000, 건당 \$50 미만.

FFmpeg H.264 - 16년 된 취약점

슬라이스 번호 65535가 센티널 값과 충돌하는 정수 절단 취약점. 5백만 번의 피징에서도 미발견. 코드의 의미적 구조 분석으로 발견.

FreeBSD NFS RCE - CVE-2026-4747

17년 된 원격 코드 실행 취약점. 인증 없이 인터넷을 통해 루트 권한 획득. 20개의 ROP 가젯 체인을 6개 패킷에 분할. 완전 자율 발견/익스플로잇.

Linux 커널 권한 상승

2-4개의 개별 취약점을 체인으로 연결. KASLR 우회 + 힙 스프레이 + UAF로 루트 획득. 비용 \$1,000-\$2,000, 반일 소요.

왜 기존 도구는 실패했는가?

핵심 인사이트: Coverage에서 Interaction으로

기존 SAST/퍼저는 '탐지 범위(coverage)' 중심으로 설계되었습니다. Mythos가 발견한 취약점들은 **구성요소 간 상호작용(interaction)**

에서 발생하는 논리적 결함으로, 의미론적 추론이 필수적입니다. CVSS 점수로 개별 취약점을 평가하는 기존 체계에서 **취약점 경로 그래프**

기반 관리로 전환이 필요합니다.


SECTION 03

아키텍처 및 혁신 요소

Mythos System Card(245페이지)와 레드팀 보고서를 종합하면, 핵심 아키텍처 혁신은 다음 4가지로 요약됩니다:

혁신 요소	설명	이전 모델 대비
확장된 추론 컨텍스트	전체 코드베이스를 수백만 토큰 규모로 동시 추론. 서로 무관해 보이는 모듈 간 상호작용 분석	Opus 4.6: 제한된 파일 단위 분석
재귀적 자기 수정 루프	코드 실행 결과 관찰 → 논리 오류 식별 → 가설 수정 → 재시도를 인간 개입 없이 반복	Opus 4.6: 단일 완성 생성
네이티브 시스템 도구 통합	디버거, 터미널, 컨테이너 환경과 직접 상호작용. ASan/GDB 자율 활용	Opus 4.6: 제한된 도구 연동
에이전틱 스케폴딩	장기 목표를 하위 과제로 분해. 정찰 → 발견 → 개발 → 검증의 파이프라인 자율 관리	Opus 4.6: 단일 세션 작업

Mythos의 에이전틱 탐색 프로세스



Glasswing 프로젝트 구조

Anthropic은 Mythos를 공개하지 않고, **Project Glasswing**이라는 방어적 배포 전략을 채택했습니다:

- **참여 조직:** Google, Microsoft, Apple, CrowdStrike, Cisco, AWS, Linux Foundation 등 약 40개 기관
- **투자 규모:** \$1억 사용 크레딧 + \$400만 오픈소스 지원금
- **접근 방식:** AWS Bedrock / Google Vertex AI를 통한 허가제 배포
- **배포 시기:** 2026년 7월 초 취약점 공개 보고서 발표 예정

SECTION 04

벤치마크 성과 비교

벤치마크	Mythos Preview	Claude Opus 4.6	향상
USAMO 2026	97.6%	42.3%	+55.3%p
SWE-bench Pro	77.8%	53.4%	+24.4%p
SWE-bench Verified	93.9%	-	최고 성능
CyBench CTF	100%	-	포화
CyberGym 취약점 재현	83.1점	66.6점	+16.5점
Firefox 147 익스플로잇	181/수백회	2/수백회	90x
OSS-Fuzz Tier 5 - 완전 제어	10건	1건	10x
익스플로잇 최초 성공률	83%	~1%	83x

≡ AISLE 연구 결과

AI 보안 스타트업 AISLE은 소형 오픈모델(36억 파라미터)도 FreeBSD 취약점을 재현 가능함을 확인. 51억 파라미터 오픈 모델은 OpenBSD 취약점의 핵심 분석 체인을 독립적으로 재구성. "경쟁 우위를 만드는 해자(moat)는 모델 자체가 아니라 시스템"이라고 결론.


오픈소스 재현: Mythos Research Edition

Keyvan Hardani가 개발한 **Mythos Research Edition**은 Glasswing 스케폴드를 공개된 Claude Opus 4.7으로 재현한 오픈소스 프로젝트입니다.

핵심 비교

항목	Anthropic Mythos	Research Edition
모델	claude-mythos-preview - 전용 체크포인트	claude-opus-4-7 - 범용
접근	초대제 - 약 40개 기관	Apache 2.0 - 누구나
스캔 범위	1,000개 파일	10개 파일 기본 - 설정 가능
회당 비용	\$20-\$50	\$0.30-\$1.50
취약점 발견	완전 자율	동등 수준
익스플로잇 개발	풀 파이프라인	Phase 5 비공개

8단계 파이프라인 구조



≡ 실증 결과

Research Edition은 모든 감사 대상에서 최소 1건 이상의 검증된 취약점을 발견. C/C++, Python, PHP, JavaScript/TypeScript, 임베디드 펌웨어, Linux 커널 모듈 등 전 언어 대상 일관된 성과. 다수의 CVE 및 GitHub Security Advisory 발행 실적 보유.

SECTION 06

최신 Claude 모델로의 구현 가능성 평가

Claude Opus 4.7 기반 구현 가능 영역

구현 가능 취약점 발견

- 전체 코드베이스 의미론적 분석
- 데이터 플로우 추적 및 크로스파일 상호작용 분석
- 메모리 안전성 위반 탐지
- 로직 취약점 식별 - 인증 우회, CSRF, SQLi
- 싱크 기반 슬라이싱 + 에이전틱 헌팅
- 회의적 검증을 통한 오탐 제거

* Claude Security 공개 베타 기반으로 즉시 활용 가능

부분 구현 익스플로잇 개발

- 기본 PoC 생성 - 크래시 재현
- 단일 취약점 익스플로잇 - 단순 버퍼오버플로우
- N-day 취약점의 기본 익스플로잇화
- 크로스캐시 리클레임 등 복잡 기법은 제한적
- JIT 힙스프레이, 커널 LPE 체인은 전용 모델이 우세

* 다단계 체인 익스플로잇은 Mythos 전용 체크포인트 필요

구현 전략: "발견은 동등, 익스플로잇은 방어 목적으로 제한"

국내 금융사 적용 핵심 결론

취약점 발견(Discovery)

측면에서 Claude Opus 4.7은 Mythos의 80% 이상을 재현 가능합니다. 특히 Research Edition의 실증 데이터가 이를 입증합니다. 금융사에 필요한 것은 "공격 무기화"가 아니라 "선제적 발견과 패치"이므로, 공개 모델만으로 충분한 방어적 가치를 확보할 수 있습니다.

Claude Security vs Mythos vs 기존 SAST 비교

기능	기존 SAST SonarQube/Checkmarx	Claude Security Opus 4.7 베타	Mythos Glasswing
패턴 매칭	강점	강점	강점
의미론적 추론	불가	가능	최강
크로스파일 분석	제한적	가능	최강
취약점 체이닝	불가	부분	자율
자율 익스플로잇	불가	제한	완전
논리적 결함 탐지	불가	가능	최강
비용 - 프로젝트당	라이선스 고정비	\$0.30-\$1.50/회	\$20-\$50/회
접근성	공개	공개 베타	초대제

SECTION 07

국내 금융사 적용 방안

금융권 사이버보안 위협 환경 변화

ECB 긴급 소집

유럽중앙은행이 은행들을 소집하여 AI 사이버보안 리스크 논의. 83% 최초 시도 성공률의 자율 익스플로잇 위협에 대한 대응 요구.

시간 압박의 현실

CrowdStrike: 매 29분마다 사이버 공격 발생(2024년 대비 65% 가속). AI 기반 공격 89% 증가. 기존 인간 대응 속도로는 불가.

규제 압력

EU AI Act 2026년 8월 시행 - 고위험 AI 감사 의무, 매출 3% 벌금. 국내: 전자금융감독규정 개정, 금융위 AI 보안 가이드라인 강화 예상.

레거시 시스템 위험


금융사 핵심 인프라의 C/C++ 레거시 코드가 Mythos급 공격의 주요 타겟. 10-20년 이상 존재해온 미발견 취약점 위험.

국내 금융사 특화 적용 영역

영역	대상 시스템	AI 보안 적용 방안	우선순위
코어뱅킹	계정계/채널계 C/C++ 코드	메모리 안전성 + 논리 결함 스캔	최우선
전자금융	인터넷뱅킹/모바일뱅킹 앱	인증우회, 세션관리, API 취약점	최우선
FDS/AML	이상거래탐지/자금세탁방지	우회 로직 분석, 규칙 역공학 방어	높음
클라우드 인프라	AWS/Azure IAM, 네트워크	설정 오류, 권한 상승 경로 분석	높음
오픈소스 의존성	npm, Maven, pip 패키지	공급망 취약점 사전 스캔	중간
암호화 구현	TLS, AES-GCM, PKI	구현 오류 탐지 - Mythos 사례 참조	중간

SECTION 08

구현 아키텍처: AWS 기반 금융사 AI 보안 플랫폼



핵심 구성 요소

1. Amazon Bedrock + Claude Opus 4.7

금융 데이터 주권 보장. 서울 리전에서 실행. Extended Thinking 활성화로 깊은 추론. 코드 100만 토큰 이상 처리.

2. AWS Security Agent

풀 리포지토리 코드 스캔 프리뷰. 온디맨드 침투 테스트. 검증된 보안 리스크 리포팅. CI/CD 통합 자동화.

3. Agentic Scaffold

Mythos Research Edition 파이프라인을 ECS Fargate에 배포. 싱크 슬라이싱 → 파일 랭킹 → 에이전틱 헌트 → 회의적 검증.

4. Security Hub 통합

발견 사항을 ASFF 포맷으로 Security Hub에 전달. 기존 보안 운영 워크플로우와 자연스러운 통합.

Extended Thinking 활용 전략


☰ Claude Opus 4.7 Extended Thinking = Mythos의 핵심 역량 재현 키

Mythos의 재귀적 자기수정 루프는 Extended Thinking의 고급 활용으로 유사하게 구현 가능합니다. 핵심 설정:

- budget_tokens: 50000+ — 복잡한 취약점 체인 추론에 충분한 사고 시간 부여
- 고수준 지시 우선 — "이 코드의 보안 취약점을 깊이 생각하라"가 단계별 지시보다 효과적

SECTION 09

구현 로드맵



단계별 상세

Phase	기간	핵심 활동	예상 성과
Phase 1 Foundation	2026 Q3 2-3개월	- Claude Security 베타 접근 확보 - AWS Security Agent 프리뷰 적용 - 보안팀 AI 도구 교육 - 파일럿 프로젝트 선정	- 첫 AI 발견 취약점 보고 - 기존 SAST 대비 탐지율 비교 - ROI 초기 측정
Phase 2 Discovery	2026 Q3-Q4 3개월	- Mythos Research Edition 스캐폴드 ECS 배포 - 코어뱅크 C/C++ 레거시 집중 스캔 - CI/CD 게이트 통합 - 발견-검증-패치 워크플로우 확립	- 레거시 코드 심층 취약점 식별 - 패치 주기 단축 - 주 단위 - Security Hub 통합 대시보드
Phase 3 Scale	2027 Q1 3개월	- 전사 확대 - 100+ 리포지토리 - 자동 패치 제안 시스템 - 오픈소스 SCA 연속 모니터링 - N-day 익스플로잇 위험도 자동 평가	- 전사 취약점 가시성 확보 - MTTD/MTTR 50% 이상 단축 - 규정 준수 자동 증빙
Phase 4 Advanced	2027 Q2 3개월	- 취약점 그래프 기반 체인 분석 - AI 레드팀 자동화 - Glasswing 파트너 프로그램 참여 추진 - 클라우드 인프라 보안 자동화	- 공격 경로 사전 차단 - Glasswing급 보호 수준 - 산업 리더십 확보

\$0.30-\$1.50

스캔당 비용
Research Edition

80%+

Mythos 발견 능력
재현율

50x

보안 로그 분석
생산성 향상

72시간

패치 적용 목표
공개 후 기한

SECTION 10

참고소스

핵심 1차 소스

#	제목	소스	설명
1	Assessing Claude Mythos Preview's Cybersecurity Capabilities	Anthropic Red Team	Mythos 사이버보안 능력 공식 기술 보고서. Nicholas Carlini 외 25명 저자.
2	Project Glasswing - Securing Critical Software	Anthropic	Mythos 방어적 배포 전략 및 파트너 프로그램 공식 페이지.
3	Mythos and the Unverified Cage: Z3-Based Verification	arXiv	Mythos 샌드박스 탈출 사건 분석 및 Z3 기반 정형 검증 제안 논문.
4	Mythos Research Edition	GitHub	공개 Claude Opus 4.7 기반 Glasswing 스캐폴드 재현. Apache 2.0.
5	Amazon Bedrock - Claude Mythos Preview	AWS	AWS Bedrock을 통한 Mythos 게이트된 리서치 프리뷰 접근 공지.

금융 업계 분석

#	제목	소스	설명
6	미토스에 놀란 세계...사이버보안 새 시대 예고	ZDNet Korea	7가지 취약점 유형 분석, Glasswing 프로젝트 국문 상세 보도.
7	What Claude Mythos Means for Financial Services	Linklaters	금융사 운영 회복탄력성 관점의 Mythos 영향 법률 분석.
8	Banking Industry Not Ready for AI-Boosted Hackers	American Banker	커뮤니티 뱅크 관점의 AI 해킹 위기 분석.
9	Claude Mythos in Banking: AI on the Way to InfoSec	Banking.Vision	금융 부문 AI 보안 전환 필요성 분석.

#	제목	소스	설명
10	ECB Convenes Banks Over AI Cybersecurity Risks	EIN News	ECB의 Mythos 대응 은행 긴급 소집 보도.

기술 구현 및 AWS

#	제목	소스	설명
11	AWS Security Agent	AWS	프론티어 보안 에이전트. 온디맨드 침투 테스트, 풀 리포지토리 스캔.
12	Claude Security Public Beta	Anthropic	Opus 4.7 기반 취약점 스캔/패치 공개 베타. 금융사 즉시 활용 가능.
13	CrowdStrike + Claude Opus 4.7 통합	CrowdStrike	Falcon 플랫폼에 Opus 4.7 통합. AI 취약점 발견/패치 자동화.
14	Building AI Defenses at Scale	AWS Security Blog	보안 로그 분석 50x 생산성 향상 사례. SecOps AI 자동화.
15	Claude Mythos Architecture Analysis	Substack	Mythos 아키텍처 추정 분석 - 4가지 핵심 혁신 요소 정리.
16	Anthropic Mythos Complete Guide 2026	CoderSera	Mythos 종합 가이드 - 벤치마크, 배포 전략, 기술 상세.