

Claude Mythos 분석 및 국내 금융사 적용 방안

Anthropic의 미공개 프론티어 모델 Mythos의 Model+Scaffold 구조를 분석하고, 최신 공개 Claude 모델로 국내 금융기관 사이버보안을 강화하는 Agent-based 전략을 제시합니다.

SECTION 01

Executive Summary

2026년 4월, Anthropic은 **Claude Mythos Preview**를 발표하며 애플리케이션 보안의 새로운 시대를 열었습니다. Mythos는 단순 모델이 아닌 "**Model + Scaffold = Agent**" 구조로, 기존 Rule-based/LLM-based 보안을 넘어 완전한 **Agent-based 보안**의 시대를 예고합니다.

90x

이전 모델 대비
익스플로잇 성공률

27년

최장 미발견
취약점 기간

11건

Opus 4.7 Unique
Findings - 자체 실험

\$0.30

스캔당 최소 비용
Research Edition

핵심 결론: "Scaffold가 핵심이다"

자체 실험 결과,

OSS-LLM을 제외하면 모델 간 취약점 발견 수 차이가 크지 않습니다

(Opus 4.7: 11, Opus 4.6: 10, Sonnet 4.6: 9). 진짜 차이를 만드는 것은 모델이 아닌

Scaffold(에이전틱 파이프라인)

입니다. 이는 공개 모델로도 Mythos급 보안 체계를 구축할 수 있음을 의미합니다.

SECTION 02

Application Security의 진화

보안 도구의 진화는 3단계로 구분됩니다. Mythos는 Phase 3 Agent-based의 선두주자입니다.

1990s ~ 2020s

Phase 1. Rule-based

SAST → DAST → 코드 리뷰

정규식 패턴 매칭, 시그니처 기반 탐지. 알려진 취약점만 탐지 가능. 높은 오탐률.

2023 ~ 2025

Phase 2. LLM-based

SAST + LLM → DAST + LLM

LLM이 코드 의미를 이해. 컨텍스트 기반 분석. 하지만 단발성 질의-응답 구조의 한계.

2026 ~

Phase 3. Agent-based

Google Naptime → Anthropic Mythos

자율 에이전트가 탐색-발견-검증-익스플로
잇 전 과정을 인간 개입 없이 수행. 재귀적
추론.

Phase 3의 핵심 차별점

Agent-based는 단순히 "LLM이 더 똑똑해진 것"이 아닙니다.


자율적 목표 분해 → 도구 사용 → 결과 관찰 → 가설 수정 → 재시도

의 폐쇄 루프를 갖춘 완전한 에이전트입니다. Google Naptime이 2025년 초기 형태를 보여줬고, Mythos가 2026년 4월 이를 완성형으로 시연했습니다.

SECTION 03

Mythos = Model + Scaffold → Agent

Mythos의 핵심 구조는 두 개의 동심원으로 표현됩니다: **내부원(Model)**은 claude-mythos-preview 체크포인트, **외부원(Scaffold)**은 에이전트 파이프라인입니다. 이 둘이 결합되어 완전한 Agent가 됩니다.



Mythos를 Mythos답게 만드는 것: Scaffold

Model만으로는 부족

아무리 뛰어난 모델이라도 단일 프롬프트로는 복잡한 보안 분석을 수행할 수 없습니다. 모델은 "두뇌"이고 Scaffold는 "몸과 도구"입니다.

Scaffold가 핵심 경쟁력

Mythos Research Edition이 증명: 공개 모델(**Opus 4.7**) + 동일 Scaffold = 발견 능력 **80%+** 재현. 전용 체크포인트가 빛나는 곳은 고급 익스플로잇 개발뿐.

우리가 구축할 수 있는 것

Model은 Anthropic 종속이지만, **Scaffold는 우리가 직접 구축** 가능합니다. 이것이 국내 금융사 AI 보안의 실질적 기회입니다.

자체 실험이 증명한 사실

"생각보다 차이가 나지 않는다 (OSS-LLM 빼면)"

동일 Scaffold에서 모델별 Unique Findings 비교 결과:

.

Opus 4.7: 11건

(critical 1 + high 다수)

.

Opus 4.6: 10건

(대부분 high/medium)

.

Sonnet 4.6: 9건

(high/medium)

.

Kimi K2: 5건

(유일하게 큰 격차)

→ Frontier 모델 간에는 Scaffold의 품질이 결정적 차이를 만듭니다. OSS-LLM만 성능 격차가 뚜렷합니다.

SECTION 04

Security Stack과 새로운 위협

기존 보안 체계는 5개 층(네트워크 → 엔드포인트 → 아이덴티티 → 탐지/대응 → 애플리케이션)으로 "이미 알려진 위협"을 방어합니다. Mythos가 보여준 것은 이 전체 스택을 우회하는 "새로운 위협"입니다.

기존 방어 체계 vs 새로운 위협

계층	방어 수단	대응 대상 - 이미 알려진 위협
1차 네트워크	방화벽, WAF, IDS	SQL injection 페이로드, 알려진 패턴
2차 엔드포인트	EDR, 백신	악성 첨부파일, 멀웨어, 의심 행위
3차 아이덴티티	IAM, MFA	도용 비번, 무차별 로그인
4차 탐지/대응	SIEM, SOC	권한 상승 후 비정상 유출
5차 애플리케이션	SAST, DAST, 리뷰	알려진 취약점 패턴

새로운 위협: AI Agent가 발견하는 Zero-day


기존 5차 방어 체계(SAST/DAST/리뷰)는 알려진 패턴만 탐지합니다.
Mythos급 AI는 5차 방어를 완전히 우회하는 미지의 논리적 취약점을 발견합니다.
→ "같은 무기(AI Agent)로 방어하지 않으면 대응 불가"

SECTION 05

금융사 노출면(Exposure) 분석

Exposure 1: Reverse Engineering 위험

사내 소스코드가 빌드를 거쳐 바이너리(모바일 banking 앱, HTS, ATM)로 배포되면, 누구나 다운로드할 수 있습니다. Mythos RE(Reverse Engineering)는 이 바이너리를 분석하여 취약점을 발견합니다.



Anthropic 시연: CLOSED 브라우저

샌드박스 escape — JIT heap spray로 렌더러 샌드박스 탈출. 소스코드 없이 바이너리만으로 달성.

Anthropic 시연: CLOSED OS

권한 상승 — 데스크톱 priv-esc chain. KASLR 우회 + UAF 결합으로 커널 레벨 접근.

Anthropic 시연: 스마트폰 펌웨어

root 획득 — firmware exploit으로 디바이스 완전 제어. 금융앱 격리 우회 가능성.

▲ 금융사 시사점

모바일 banking 앱, HTS(Home Trading System), ATM 소프트웨어는 모두 공개 배포됩니다. Mythos급 AI는 이 바이너리를 분석하여 사내 소스코드 없이도 취약점을 발견하고 익스플로잇을 개발할 수 있습니다.

기존 "소스코드 비공개 = 안전"이라는 전제가 무너졌습니다.

Exposure 2: Supply Chain 위험

금융사 사내 백엔드(코어뱅킹, 마이데이터, 오픈뱅킹 API)는 4가지 공급망 경로를 통해 공격에 노출됩니다. 모든 요소를 다 막는 건 불가능합니다.

1. OSS 의존성

- npm, pip, maven 패키지
- log4j 사례: 단일 취약점이 전 산업 영향
- Mythos가 주요 OSS에서 수천 건 발견

2. SI/외주

- 참조 솔루션, 패턴 공유
- "한 군데 뚫리면 동일 패턴" 전파
- 같은 프레임워크 사용하는 금융사 다수

3. 외부 인력

- 컨설턴트, 외주 개발자
- 노트북, 개인 git을 통한 코드 유출

4. 컨설팅/감사

- 보안 검토, 외부 진단 과정
- 코드 외부 반출 발생

SECTION 06

모델 벤치마크 비교

자체 실험: Unique Findings 및 심각도 비교

동일 Scaffold에서 모델별 취약점 발견 수를 비교한 자체 실험 결과입니다.

모델	Unique Findings	Critical	High	Medium	Low	비고
Claude Opus 4.7	11	1	5	4	1	최고 성능
Claude Opus 4.6	10	0	5	4	1	Opus 4.7과 근접
Claude Sonnet 4.6	9	0	4	4	1	비용 대비 우수
Kimi K2	5	0	2	2	1	OSS-LLM 한계

핵심 인사이트: "Scaffold가 해자(Moat)이다"

Frontier 모델(Opus 4.7/4.6, Sonnet 4.6) 간에는 Unique Findings 차이가 1-2건(9~11건)에 불과합니다. 반면 OSS-LLM(Kimi K2)은 5건으로 큰 격차를 보입니다.

결론: Frontier 모델 중 어떤 것을 선택하든 Scaffold의 품질이 최종 성과를 결정합니다.

이는 금융사가 공개된 Claude Opus 4.7만으로도 경쟁력 있는 보안 체계를 구축할 수 있음을 의미합니다.


Anthropic 공식 벤치마크 (Mythos vs 이전 세대)

벤치마크	Mythos Preview	Opus 4.6	향상
USAMO 2026	97.6%	42.3%	+55.3%p
SWE-bench Pro	77.8%	53.4%	+24.4%p
CyBench CTF	100%	-	포화
CyberGym 취약점 재현	83.1점	66.6점	+16.5점
Firefox 147 익스플로잇	181회	2회	90x
익스플로잇 최초 성공률	83%	~1%	83x

SECTION 07

Scaffold 상세 구조 (8-Phase Pipeline)


Mythos의 Scaffold는 8단계 파이프라인으로 구성됩니다. 이 구조가 단일 LLM 호출과 Agent를 구분짓는 핵심 요소입니다.



각 Phase의 역할과 구현 방법

Phase	역할	핵심 기술	Claude 구현
P0	언어/프레임워크 감지	파일 확장자 + 구조 분석	Python 스크립트 (모델 불필요)
P1	위험 함수(Sink) 기반 코드 슬라이스 추출	Semgrep/CodeQL 스타일 싱크 매칭	정적 분석 도구 + Python
P2	파일 위험도 순위 결정	싱크 밀도 + 인터넷 노출 + 권한 분석	Claude 1회 호출 (저비용)
P2.5	격리 실행 환경 구축	Docker/Firecracker 샌드박스	ECS Fargate / Lambda
P3	자율 취약점 탐색 (K회 독립)	Extended Thinking + 도구 사용 + 재시도	Claude 핵심 - 비용의 70%
P3.5	발견에 대한 적대적 반박	2차 에이전트가 오탐 공격	Claude 별도 세션 (대항적)
P4	최종 검증 판정	3차 에이전트가 CONFIRMED/DISMISSED	Claude 판정 (가장 보수적)
P6-7	보고서 + FP 메모리 기록	ASFF 포맷 + DynamoDB 저장	Python + AWS 서비스

핵심 Phase 3: 에이전틱 헌트 상세



다음 가설 or 종료

≡ pass_at_k 전략: 왜 K회 독립 실행인가?

temperature=1.0

에서 K회(기본 3회) 독립 실행하면 각 실행마다 다른 관점에서 취약점을 탐색합니다. 1회 실행에서 놓친 취약점을 다른 실행에서 발견할 확률이 높아집니다. 이것이 Mythos Research Edition이 건당 \$0.30-\$1.50으로 실질적 성과를 내는 비결입니다.

SECTION 08

최신 Claude 모델로의 구현 가능성 평가

결론: "Model은 충분하다. Scaffold를 구축하라."

즉시 구현 가능

- 취약점 발견 — Opus 4.7로 Mythos의 80%+ 재현
- 의미론적 코드 분석 — 크로스파일 상호작용 추적
- 에이전틱 Scaffold — 8단계 파이프라인 전체
- 회의적 검증 — Multi-Agent 오탐 제거
- CI/CD 통합 — 배포 게이트 자동화
- 자동 패치 제안 — 발견 즉시 수정 코드 생성

Mythos 전용 필요

- 고급 익스플로잇 개발 — JIT heap spray, ROP chain
- 바이너리 역공학 — 소스 없는 closed 분석
- 4+ 취약점 체이닝 — 복합 공격 경로
- 커널 LPE 자율 개발 — KASLR bypass chain
- 대규모 자율 스캔 — 1,000파일 단일 실행

* 그러나 방어 목적에는 "발견"만으로도 충분

왜 방어자에게는 "발견"만으로 충분한가?

≡ 공격자 vs 방어자의 비대칭성

•

공격자

: 발견 + 익스플로잇 개발 + 무기화가 모두 필요 (Mythos 전용 영역)

•

방어자

:


발견 + 패치만 하면 됨

(공개 모델로 충분)

금융사의 목표는 "공격 무기 개발"이 아니라 "선제적 발견 + 즉각 패치"입니다. 이 목표에서 Claude Opus 4.7 + 적절한 Scaffold는 Mythos의 발견 능력을 80% 이상 재현

하면서 비용은 25-50배 저렴합니다.

국내 금융사 적용 아키텍처



Extended Thinking 활용 전략

Mythos의 재귀적 자기수정 = Extended Thinking

Mythos의 핵심 능력인 "자기 수정 루프"는 Claude의 Extended Thinking(budget_tokens: 50,000+)으로 재현 가능합니다. 모델이 내부적으로 깊이 추론한 후 응답합니다.

핵심 설정

- **budget_tokens: 50,000+** — 복잡한 취약점 추론
- **temperature: 1.0** — Extended Thinking 필수값
- **고수준 지시 우선** — "깊이 생각하라" > 단계별 지시
- **Think Tool 패턴** — 중간에 멈추고 추가 정보 판단

비용 최적화


- P0-P2: 모델 미사용 또는 저비용 1회 호출
- P3: **비용의 70%** — Extended Thinking 집중
- P3.5-P4: 짧은 검증 호출
- 총 \$0.50-\$3.00/스캔 (타겟 8-10파일 기준)

SECTION 10

구현 로드맵

국내 금융사 AI Agent-based 보안 구축 로드맵

전체화면



Phase	기간	핵심 활동	대응 위험
Phase 1 PoC	2026 Q3 2-3개월	• Claude Security 베타 + AWS Security Agent • Scaffold P0-P2 구축 (언어감지/싱크/랭킹) • 파일럿 프로젝트 1-2개 선정	기존 Security Stack 강화 (5차 Application 보완)

Phase	기간	핵심 활동	대응 위협
Phase 2 Core	2026 Q3-Q4 3개월	- Scaffold P3-P4 구축 (에이전틱 헌트/검증) - 코어뱅크 C/C++ 레거시 집중 스캔 - CI/CD 배포 게이트 자동화	새로운 위협 대응 (Zero-day 선제 발견)
Phase 3 Scale	2027 Q1 3개월	- 전사 100+ 리포 확대 - Supply Chain(OSS/외주) 연속 모니터링 - 자동 패치 제안 시스템	Exposure 2 대응 (공급망 위협)
Phase 4 Advanced	2027 Q2 3개월	- 바이너리 난독화/방어 강화 - Glasswing 파트너 참여 추진 - AI Red Team 자동화	Exposure 1 대응 (RE 위협)

\$50-300

월간 스캔 비용
100회 기준

80%+

Mythos 발견 능력
재현율

72시간

패치 적용 목표
발견 후 기한

50x

보안 로그 분석
생산성 향상

SECTION 11

참고소스

핵심 1차 소스

#	제목	소스	설명
1	Assessing Claude Mythos Preview Cybersecurity Capabilities	Anthropic Red Team	공식 기술 보고서. 8-Phase Scaffold 구조 최초 공개.
2	Project Glasswing	Anthropic	Mythos 방어적 배포 전략. AWS 포함 40개 기관 참여.
3	Mythos Research Edition	GitHub	Opus 4.7로 Scaffold 재현. Apache 2.0. \$0.30-\$1.50/스캔.
4	Mythos and the Unverified Cage - Z3 Verification	arXiv	Mythos 샌드박스 탈출 분석. CWE-190 정형 검증 제안.
5	Amazon Bedrock Claude Mythos Preview	AWS	Bedrock 게이트된 리서치 프리뷰 접근.

금융 업계 분석

#	제목	소스	설명
6	미토스에 놀란 세계...사이버보안 새 시대 예고	ZDNet Korea	Glasswing 12개 기관 참여, 7월 보고서 발표 예정.
7	Mythos and Financial Services Resilience	Linklaters	금융사 운영 회복탄력성 법률 분석.
8	ECB Convenes Banks Over AI Cybersecurity	EIN News	ECB 긴급 소집. 83% 성공률 자율 익스플로잇 경고.

#	제목	소스	설명
9	Banking Not Ready for AI-Boosted Hackers	American Banker	커뮤니티 뱅크 AI 해킹 위기 분석.

기술 구현

#	제목	소스	설명
10	AWS Security Agent	AWS	프론티어 보안 에이전트. 폴 리포 스캔 프리뷰.
11	Claude Security Public Beta	Anthropic	Opus 4.7 기반 취약점 스캔/패치.
12	Using LLMs to Secure Source Code	Anthropic	Discovery-Verification-Triage-Patching 4단계 가이드.
13	Anthropic Mythos Complete Guide 2026	CoderSera	Mythos 종합 가이드. 벤치마크/배포 상세.
14	Mythos Architecture Analysis	Substack	4가지 아키텍처 혁신. System Card 245페이지 분석.
15	Extended Thinking Tips	Anthropic Docs	Extended Thinking 프롬프트 엔지니어링 공식 가이드.